

Inteligencia Artificial

620454 - 1

Calidad y
preparación de datos

Integrantes:

Juan Foti

Cristóbal Cheguán

Benjamín Quiñones

Constanza Gavilán



Problemas encontrados

Datos nulos/faltantes: 1335

Datos atípicos: 294

Datos con inconsistencias: 62

Datos duplicados: 100



Datos nulos

Depende de la cantidad de datos nulos y si son de tipo categóricas o numéricas :

Si la cantidad de datos null <5%, se imputan.

.....

Categóricas: Se seleccionan por su moda

Numéricas: Si tiene una desviación estándar alto, se utiliza la mediana, sino, se utiliza la media.




STU-10307	24	22.93	100	6.99	100	8.18	7.09	No		5.36
-----------	----	-------	-----	------	-----	------	------	----	--	------

Datos atípicos

Los datos atípicos se pueden atender con distintos tratamientos:

Eliminar a los datos que tengan una desviación estándar muy alta.

Windsorization, que en vez de eliminar, los limita a percentiles específicos.



Datos con inconsistencias

Para los datos que tengan inconsistencias, detecta a los datos que son imposibles, y los elimina para evitar confusión de algoritmo y resultados basura.

	StudentID	Age	StudyHours	Attendance	PreviousGPA	AssignmentsCompleted	SleepHours	InternetHours	Scholarship	Program	FinalGrade
5	STU-11440	21.0	13.81	-19.961240	6.69	93.82	5.72	5.150000	Sí	Ingeniería Industrial	4.650000
16	STU-13555	26.0	6.08	111.567467	4.69	73.54	NaN	6.440000	No	Ingeniería Civil	3.050000
237	STU-10593	23.0	18.68	88.640000	6.69	100.00	5.34	68.116278	Sí	Ingeniería Industrial	4.910000
263	STU-12872	NaN	12.20	80.960000	5.54	81.02	6.82	1.530000	No	Ingeniería Civil	-1.328245









Datos duplicados

A los datos duplicados se le eliminan para evitar contaminación. Solo 100 de los 5100 registros totales (1,961%) son duplicados, por lo que la eliminación de estos no tendrá repercusiones significativas negativas en el análisis de la data.


STU-10095	22	10.62	56.34	5.6	70.73	7.96	4.03	Ingeniería	3.43
STU-10095	22	10.62	56.34	5.6	70.73	7.96	4.03	Ingeniería	3.43

Datos atípicos graficados




Comparación de gráficas



Antes del tratamiento: Attendance



Después del tratamiento: Attendance




Comparación de gráficas




Comparación de gráficas



Antes del tratamiento: StudyHours





Después del tratamiento: StudyHours



Datos después de tratamiento



Resultados Principales



Conclusión y estado final de los datos

	Program_Normalized	FinalGrade
4	Ingeniería Informática	4.25
0	Administración	4.23
3	Ingeniería Industrial	4.21
2	Ingeniería Civil	4.13
1	Contador Auditor	4.05

Indicador	Dataset Original	Dataset Tratado
Cantidad de registros	5100	4645
Cantidad de variables	11	11
Valores faltantes (total)	1335	0
Cantidad de registros duplicados	100	0
Cantidad de inconsistencias	62	0
Cantidad de valores atípicos tratados	294	0